```
In [ ]: import matplotlib.pyplot as plt
                           from dask import dataframe as dd
                           from utils import utils
                           from IPython.display import display_html
                           import pandas as pd
                           import numpy as np
                           import os
                           PROVAS = ["NU_NOTA_CN", "NU_NOTA_CH", "NU_NOTA_MT", "NU_NOTA_LC", "NU_NOTA_REDACAO"]
                           OUTPUT = os.path.join(os.getcwd(), 'output')
                           YEARS = ['2019', '2020', '2021']
                           if not os.path.isdir(OUTPUT):
                                         os.makedirs(OUTPUT)
                           df_2019, df_2020, df_2021 = utils.setup()
In [ ]: # DESCRIÇÃO DA MÉDIA GERAL
                           media_geral_2019 = df_2019["NU_MEDIA_GERAL"].describe(include=['object', 'float64', 'int64']).apply(lambda s: npmedia_geral_2020 = df_2020["NU_MEDIA_GERAL"].describe(include=['object', 'float64', 'int64']).apply(lambda s: npmedia_geral_2021 = df_2021["NU_MEDIA_GERAL"].describe(include=['object', 'float64', 'float64']).apply(lambda s: npmedia_geral_2021 = df_2
                           df = pd.concat([media geral 2019, media geral 2020, media geral 2021],
                                                                                    keys=['Descrição da Média Geral 2019',
                                                                                                          'Descrição da Média Geral 2020'
                                                                                                         'Descrição da Média Geral 2021'],
                                                                                    axis=1)
                           df
                                               Descrição da Média Geral 2019 Descrição da Média Geral 2020 Descrição da Média Geral 2021
Out[]:
```

	•	•	•
count	3701909.00	2561304.00	2238106.00
mean	522.62	526.60	535.54
std	83.65	91.52	88.96
min	0.00	0.00	0.00
25%	464.04	459.38	471.40
50%	515.02	516.88	527.32
75%	576.74	587.16	594.48
max	850.82	858.58	862.68

```
In [ ]: # DESCRIÇÃO DA MÉDIA GERAL CLASSE E
```

Out[]:

	Descrição da Média Geral 2019	Descrição da Média Geral 2019 - Classe E	Descrição da Média Geral 2020	Descrição da Média Geral 2020 - Classe E	Descrição da Média Geral 2021	Descrição da Média Geral 2021 - Classe E
count	3701909.00	1955389.00	2561304.00	1351260.00	2238106.00	1006470.00
mean	522.62	491.62	526.60	492.53	535.54	499.00
std	83.65	70.27	91.52	77.15	88.96	75.71
min	0.00	0.00	0.00	0.00	0.00	0.00
25%	464.04	445.68	459.38	439.22	471.40	448.30
50%	515.02	487.52	516.88	484.70	527.32	492.14
75%	576.74	534.70	587.16	539.76	594.48	544.86
max	850.82	817.06	858.58	837.72	862.68	839.82

```
In [ ]: # DESCRIÇÃO DA MÉDIA GERAL CLASSE D
         media_geral_classe_d_2019 = df_2019.query("Q006 == 'D'")["NU_MEDIA_GERAL"].describe(
             include=['object', 'float64', 'int64']).apply(lambda s: np.round(s, 2))
         media_geral_classe_d_2020 = df_2020.query("Q006 == 'D'")["NU_MEDIA_GERAL"].describe(
             include=['object', 'float64', 'int64']).apply(lambda s: np.round(s, 2))
         media_geral_classe_d_2021 = df_2021.query("Q006 == 'D'")["NU_MEDIA_GERAL"].describe(
         include=['object', 'float64', 'int64']).apply(lambda s: np.round(s, 2))
df = pd.concat([media_geral_2019, media_geral_classe_d_2019,
                          media geral 2020, media geral classe d 2020,
                          media_geral_2021, media_geral_classe_d_2021],
                           keys=['Descrição da Média Geral 2019',
                                  'Descrição da Média Geral 2019 - Classe D',
                                  'Descrição da Média Geral 2020',
                                  'Descrição da Média Geral 2020 - Classe D',
                                  'Descrição da Média Geral 2021',
                                  'Descrição da Média Geral 2021 - Classe D'],
                           axis=1)
         df
```

Dut[]:		Descrição da Média Geral 2019	Descrição da Média Geral 2019 - Classe D	Descrição da Média Geral 2020	Descrição da Média Geral 2020 - Classe D	Descrição da Média Geral 2021	Descrição da Média Geral 2021 - Classe D
	count	3701909.00	1109327.00	2561304.00	802390.00	2238106.00	737361.00
	mean	522.62	535.56	526.60	542.73	535.54	543.51
	std	83.65	76.85	91.52	84.90	88.96	81.55
	min	0.00	0.00	0.00	0.00	0.00	64.00
	25%	464.04	482.58	459.38	481.54	471.40	485.98
	50%	515.02	531.98	516.88	537.94	527.32	538.50
	75%	576.74	586.30	587.16	599.84	594.48	597.30
	max	850.82	826.30	858.58	847.82	862.68	845.04

```
In [ ]: # DESCRIÇÃO DA MÉDIA GERAL CLASSE C
                           media\_geral\_classe\_c\_2019 = df\_2019.query("Q006 == 'C'")["NU\_MEDIA\_GERAL"].describe("Q006 == 'C'")["NU\_MEDIA\_GER
                                        include=['object', 'float64', 'int64']).apply(lambda s: np.round(s, 2))
                           media_geral_classe_c_2020 = df_2020.query("Q006 == 'C'")["NU_MEDIA_GERAL"].describe(
                                        include=['object', 'float64', 'int64']).apply(lambda s: np.round(s, 2))
                           media_geral_classe_c_2021 = df_2021.query("Q006 == 'C'")["NU_MEDIA_GERAL"].describe(
                                        include=['object', 'float64', 'int64']).apply(lambda s: np.round(s, 2))
                           df = pd.concat([media_geral_2019, media_geral_classe_c_2019,
                                                                                media_geral_2020, media_geral_classe_c_2020,
                                                                                media_geral_2021, media_geral_classe_c_2021],
                                                                                   keys=['Descrição da Média Geral 2019'
                                                                                                        'Descrição da Média Geral 2019 - Classe C',
                                                                                                        'Descrição da Média Geral 2020',
                                                                                                        'Descrição da Média Geral 2020 - Classe C',
                                                                                                        'Descrição da Média Geral 2021',
                                                                                                        'Descrição da Média Geral 2021 - Classe C'],
                                                                                   axis=1)
                           df
```

Out[]:

```
Descrição da
                                 Descrição da Média
                                                           Descrição da
                                                                               Descrição da Média
                                                                                                          Descrição da
                                                                                                                              Descrição da Média
         Média Geral 2019
                               Geral 2019 - Classe C
                                                       Média Geral 2020
                                                                              Geral 2020 - Classe C
                                                                                                      Média Geral 2021
                                                                                                                             Geral 2021 - Classe C
               3701909.00
                                          460888.00
                                                             2561304.00
                                                                                         291823.00
                                                                                                            2238106.00
                                                                                                                                        358669.00
count
mean
                   522.62
                                              583.91
                                                                  526.60
                                                                                             597.33
                                                                                                                 535.54
                                                                                                                                           588.45
  std
                    83.65
                                               80.75
                                                                   91.52
                                                                                              87.30
                                                                                                                  88.96
                                                                                                                                             85.47
                     0.00
                                                0.00
                                                                    0.00
                                                                                               0.00
                                                                                                                   0.00
                                                                                                                                             0.00
  min
 25%
                   464.04
                                              528.38
                                                                  459.38
                                                                                             536.24
                                                                                                                 471.40
                                                                                                                                           527.66
 50%
                   515.02
                                              586.22
                                                                  516.88
                                                                                             599.94
                                                                                                                 527.32
                                                                                                                                            588.78
 75%
                   576.74
                                              641.78
                                                                  587.16
                                                                                             660.58
                                                                                                                 594.48
                                                                                                                                           649.60
                   850 82
                                              845 00
                                                                  858 58
                                                                                             858 58
                                                                                                                 862 68
                                                                                                                                           862 68
 max
```

```
In []: # DESCRIÇÃO DA MÉDIA GERAL CLASSE B

media_geral_classe_b_2019 = df_2019.query("Q006 == 'B'")["NU_MEDIA_GERAL"].describe(
    include=['object', 'float64', 'int64']).apply(lambda s: np.round(s, 2))
media_geral_classe_b_2020 = df_2020.query("Q006 == 'B'")["NU_MEDIA_GERAL"].describe(
    include=['object', 'float64', 'int64']).apply(lambda s: np.round(s, 2))
media_geral_classe_b_2021 = df_2021.query("Q006 == 'B'")["NU_MEDIA_GERAL"].describe(
    include=['object', 'float64', 'int64']).apply(lambda s: np.round(s, 2))
df = pd.concat([media_geral_2019, media_geral_classe_b_2019,
```

Out[]:

Descrição da Média Geral 2021 - Classe B	Descrição da Média Geral 2021	Descrição da Média Geral 2020 - Classe B	Descrição da Média Geral 2020	Descrição da Média Geral 2019 - Classe B	Descrição da Média Geral 2019	
95692.00	2238106.00	84249.00	2561304.00	129646.00	3701909.00	count
619.80	535.54	630.08	526.60	620.45	522.62	mean
84.68	88.96	84.47	91.52	77.41	83.65	std
0.00	0.00	125.08	0.00	0.00	0.00	min
562.92	471.40	574.94	459.38	571.26	464.04	25%
624.51	527.32	636.28	516.88	626.48	515.02	50%
681.34	594.48	691.28	587.16	676.10	576.74	75%
851.04	862.68	852.86	858.58	850.82	850.82	max


```
In [ ]: # DESCRIÇÃO DA MÉDIA GERAL CLASSE A
        media_geral_classe_a_2019 = df_2019.query("Q006 == 'A'")["NU_MEDIA_GERAL"].describe(
            include=['object', 'float64', 'int64']).apply(lambda s: np.round(s, 2))
        media_geral_classe_a_2020 = df_2020.query("Q006 == 'A'")["NU_MEDIA_GERAL"].describe(
            include=['object', 'float64', 'int64']).apply(lambda s: np.round(s, 2))
        media_geral_classe_a_2021 = df_2021.query("Q006 == 'A'")["NU_MEDIA_GERAL"].describe(
           include=['object', 'float64', 'int64']).apply(lambda s: np.round(s, 2))
        df = pd.concat([media_geral_2019, media_geral_classe_a_2019,
                        {\tt media\_geral\_2020,\ media\_geral\_classe\_a\_2020,}
                        media_geral_2021, media_geral_classe_a_2021],
                         keys=['Descrição da Média Geral 2019',
                                'Descrição da Média Geral 2019 - Classe A',
                                'Descrição da Média Geral 2020',
                                'Descrição da Média Geral 2020 - Classe A',
                                'Descrição da Média Geral 2021',
                                'Descrição da Média Geral 2021 - Classe A'],
                         axis=1)
        df
```

Out[ ]:


Descrição da Média Geral 2019	Descrição da Média Geral 2019 - Classe A	Descrição da Média Geral 2020	Descrição da Média Geral 2020 - Classe A	Descrição da Média Geral 2021	Descrição da Média Geral 2021 - Classe A
3701909.00	46659.00	2561304.00	31582.00	2238106.00	39914.00
522.62	637.32	526.60	644.74	535.54	632.34
83.65	75.49	91.52	83.97	88.96	84.49
0.00	0.00	0.00	0.00	0.00	73.16
464.04	592.66	459.38	591.84	471.40	576.34
515.02	644.88	516.88	652.10	527.32	638.49
576.74	690.94	587.16	705.76	594.48	693.86
850.82	837.48	858.58	852.76	862.68	859.96
	Média Geral 2019  3701909.00  522.62  83.65  0.00  464.04  515.02  576.74	Média Gerál 2019         Geral 2019 - Classe A           3701909.00         46659.00           522.62         637.32           83.65         75.49           0.00         0.00           464.04         592.66           515.02         644.88           576.74         690.94	Média Gerál 2019         Geral 2019 - Classe A         Média Gerál 2020           3701909.00         46659.00         2561304.00           522.62         637.32         526.60           83.65         75.49         91.52           0.00         0.00         0.00           464.04         592.66         459.38           515.02         644.88         516.88           576.74         690.94         587.16	Média Gerál 2019         Geral 2019 - Classe A         Média Gerál 2020         Geral 2020 - Classe A           3701909.00         46659.00         2561304.00         31582.00           522.62         637.32         526.60         644.74           83.65         75.49         91.52         83.97           0.00         0.00         0.00         0.00           464.04         592.66         459.38         591.84           515.02         644.88         516.88         652.10           576.74         690.94         587.16         705.76	Média Gerál 2019         Geral 2019 - Classe A         Média Gerál 2020         Geral 2020 - Classe A         Média Gerál 2021           3701909.00         46659.00         2561304.00         31582.00         2238106.00           522.62         637.32         526.60         644.74         535.54           83.65         75.49         91.52         83.97         88.96           0.00         0.00         0.00         0.00         0.00           464.04         592.66         459.38         591.84         471.40           515.02         644.88         516.88         652.10         527.32           576.74         690.94         587.16         705.76         594.48

```
In [ ]: utils.plot_hist_classes_all(df_2019, OUTPUT)
    utils.plot_hist_classes_all(df_2020, OUTPUT)
    utils.plot_hist_classes_all(df_2021, OUTPUT)
```


Número de pessoas x Media Geral - 2019 - 3701909 candidatos









## Número de pessoas x Media Geral - 2021 - 2238106 candidatos




In [ ]: utils.plot\_hist\_classes(df\_2019, OUTPUT)
 utils.plot\_hist\_classes(df\_2020, OUTPUT)
 utils.plot\_hist\_classes(df\_2021, OUTPUT)

Número de pessoas x Media Geral - 2019 - 3701909 candidatos








## Número de pessoas x Media Geral - 2021 - 2238106 candidatos



## Número de pessoas x Media Geral - 2019 - 3701909 candidatos











Número de pessoas x Media Geral - 2020 - 2561304 candidatos
































In [ ]: utils.plot\_boxplot\_descricao\_amostras([df\_2019, df\_2020, df\_2021], OUTPUT)

