main

November 17, 2022

```
[1]: import matplotlib.pyplot as plt
from dask import dataframe as dd
from utils import utils
from IPython.display import display_html
import pandas as pd
import numpy as np
import os

PROVAS = ["NU_NOTA_CN","NU_NOTA_CH","NU_NOTA_MT","NU_NOTA_LC","NU_NOTA_REDACAO"]
OUTPUT = os.path.join(os.getcwd(), 'output')
YEARS = ['2019', '2020', '2021']
if not os.path.isdir(OUTPUT):
    os.makedirs(OUTPUT)

df_2019, df_2020, df_2021 = utils.setup()
```

```
0.00
                                                                     0.00
    min
     25%
                                   464.04
                                                                   459.38
     50%
                                   515.02
                                                                   516.88
     75%
                                   576.74
                                                                   587.16
    max
                                   850.82
                                                                   858.58
            Descrição da Média Geral 2021
                               2238106.00
     count
    mean
                                   535.54
     std
                                    88.96
    min
                                     0.00
    25%
                                   471.40
    50%
                                   527.32
    75%
                                   594.48
                                   862.68
    max
[3]: # DESCRIÇÃO DA MÉDIA GERAL CLASSE E
     media_geral_classe_e_2019 = df_2019.query("Q006 == 'E'")["NU_MEDIA_GERAL"].
      ⊶describe(
         include=['object', 'float64', 'int64']).apply(lambda s: np.round(s, 2))
     media_geral_classe_e_2020 = df_2020.query("Q006 == 'E'")["NU_MEDIA_GERAL"].
      ⊶describe(
         include=['object', 'float64', 'int64']).apply(lambda s: np.round(s, 2))
     media_geral_classe_e_2021 = df_2021.query("Q006 == 'E'")["NU_MEDIA_GERAL"].
      →describe(
         include=['object', 'float64', 'int64']).apply(lambda s: np.round(s, 2))
     df = pd.concat([media_geral_2019, media_geral_classe_e_2019,
                     media_geral_2020, media_geral_classe_e_2020,
                     media_geral_2021, media_geral_classe_e_2021],
                      keys=['Descrição da Média Geral 2019',
                            'Descrição da Média Geral 2019 - Classe E',
                            'Descrição da Média Geral 2020',
                            'Descrição da Média Geral 2020 - Classe E',
                            'Descrição da Média Geral 2021',
                            'Descrição da Média Geral 2021 - Classe E'],
                      axis=1)
     df
[3]:
            Descrição da Média Geral 2019 \
                               3701909.00
     count
    mean
                                   522.62
```

83.65

515.02

0.00 464.04

std

min

25% 50%

```
75%
                                    576.74
                                    850.82
    max
            Descrição da Média Geral 2019 - Classe E \
                                            1955389.00
     count
    mean
                                                491.62
    std
                                                 70.27
    min
                                                  0.00
    25%
                                                445.68
    50%
                                                487.52
    75%
                                                534.70
    max
                                                817.06
            Descrição da Média Geral 2020 \
                                2561304.00
     count
    mean
                                    526.60
     std
                                     91.52
                                      0.00
    min
    25%
                                    459.38
     50%
                                    516.88
    75%
                                    587.16
                                    858.58
    max
            Descrição da Média Geral 2020 - Classe E \
                                            1351260.00
     count
    mean
                                                492.53
     std
                                                 77.15
    min
                                                 0.00
    25%
                                                439.22
     50%
                                                484.70
    75%
                                                539.76
                                                837.72
    max
            Descrição da Média Geral 2021
                                            Descrição da Média Geral 2021 - Classe E
     count
                                2238106.00
                                                                            1006470.00
    mean
                                    535.54
                                                                                499.00
    std
                                     88.96
                                                                                 75.71
    min
                                      0.00
                                                                                  0.00
    25%
                                    471.40
                                                                                448.30
     50%
                                    527.32
                                                                                492.14
     75%
                                    594.48
                                                                                544.86
    max
                                    862.68
                                                                                839.82
[4]: # DESCRIÇÃO DA MÉDIA GERAL CLASSE D
     media_geral_classe_d_2019 = df_2019.query("Q006 == 'D'")["NU_MEDIA_GERAL"].
      ⊶describe(
```

```
include=['object', 'float64', 'int64']).apply(lambda s: np.round(s, 2))
    media_geral_classe_d_2020 = df_2020.query("Q006 == 'D'")["NU_MEDIA_GERAL"].
      →describe(
         include=['object', 'float64', 'int64']).apply(lambda s: np.round(s, 2))
     media_geral_classe_d_2021 = df_2021.query("Q006 == 'D'")["NU_MEDIA_GERAL"].
      ⊶describe(
         include=['object', 'float64', 'int64']).apply(lambda s: np.round(s, 2))
     df = pd.concat([media_geral_2019, media_geral_classe_d_2019,
                     media_geral_2020, media_geral_classe_d_2020,
                     media_geral_2021, media_geral_classe_d_2021],
                      keys=['Descrição da Média Geral 2019',
                             'Descrição da Média Geral 2019 - Classe D',
                            'Descrição da Média Geral 2020',
                            'Descrição da Média Geral 2020 - Classe D',
                            'Descrição da Média Geral 2021',
                            'Descrição da Média Geral 2021 - Classe D'],
                      axis=1)
     df
[4]:
            Descrição da Média Geral 2019 \
     count
                               3701909.00
    mean
                                   522.62
                                    83.65
    std
                                      0.00
    min
    25%
                                   464.04
    50%
                                   515.02
    75%
                                   576.74
    max
                                   850.82
            Descrição da Média Geral 2019 - Classe D \
                                           1109327.00
     count
    mean
                                               535.56
                                                76.85
    std
    min
                                                 0.00
    25%
                                               482.58
    50%
                                               531.98
    75%
                                               586.30
                                               826.30
    max
            Descrição da Média Geral 2020 \
                               2561304.00
     count
    mean
                                   526.60
     std
                                    91.52
    min
                                     0.00
    25%
                                   459.38
    50%
                                   516.88
```

```
75%
                                   587.16
                                   858.58
    max
            Descrição da Média Geral 2020 - Classe D \
                                            802390.00
     count
                                               542.73
    mean
    std
                                                84.90
    min
                                                 0.00
    25%
                                               481.54
    50%
                                               537.94
    75%
                                               599.84
    max
                                               847.82
            Descrição da Média Geral 2021 Descrição da Média Geral 2021 - Classe D
                               2238106.00
                                                                            737361.00
     count
    mean
                                   535.54
                                                                               543.51
                                                                                81.55
     std
                                    88.96
                                                                                64.00
    min
                                      0.00
    25%
                                   471.40
                                                                               485.98
     50%
                                   527.32
                                                                               538.50
     75%
                                   594.48
                                                                               597.30
                                   862.68
                                                                               845.04
    max
[5]: # DESCRIÇÃO DA MÉDIA GERAL CLASSE C
     media geral classe c 2019 = df 2019.query("Q006 == 'C'")["NU MEDIA GERAL"].
      ⊶describe(
         include=['object', 'float64', 'int64']).apply(lambda s: np.round(s, 2))
     media_geral_classe_c_2020 = df_2020.query("Q006 == 'C'")["NU_MEDIA_GERAL"].
      ⊶describe(
         include=['object', 'float64', 'int64']).apply(lambda s: np.round(s, 2))
     media_geral_classe_c_2021 = df_2021.query("Q006 == 'C'")["NU_MEDIA_GERAL"].
      →describe(
         include=['object', 'float64', 'int64']).apply(lambda s: np.round(s, 2))
     df = pd.concat([media_geral_2019, media_geral_classe_c_2019,
                     media_geral_2020, media_geral_classe_c_2020,
                     media_geral_2021, media_geral_classe_c_2021],
                      keys=['Descrição da Média Geral 2019',
                             'Descrição da Média Geral 2019 - Classe C',
                             'Descrição da Média Geral 2020',
                            'Descrição da Média Geral 2020 - Classe C',
                            'Descrição da Média Geral 2021',
                             'Descrição da Média Geral 2021 - Classe C'],
                      axis=1)
     df
```

```
[5]:
            Descrição da Média Geral 2019 \
                                3701909.00
     count
                                    522.62
    mean
    std
                                     83.65
    min
                                      0.00
    25%
                                    464.04
    50%
                                    515.02
    75%
                                    576.74
                                    850.82
    max
            Descrição da Média Geral 2019 - Classe C \
                                             460888.00
     count
                                                583.91
    mean
                                                 80.75
     std
    min
                                                  0.00
    25%
                                                528.38
    50%
                                                586.22
    75%
                                                641.78
                                                845.00
    max
            Descrição da Média Geral 2020 \
                                2561304.00
     count
    mean
                                    526.60
     std
                                     91.52
    min
                                      0.00
    25%
                                    459.38
     50%
                                    516.88
     75%
                                    587.16
                                    858.58
    max
            Descrição da Média Geral 2020 - Classe C \
     count
                                             291823.00
    mean
                                                597.33
    std
                                                 87.30
                                                  0.00
    min
    25%
                                                536.24
     50%
                                                599.94
    75%
                                                660.58
                                                858.58
    max
                                            Descrição da Média Geral 2021 - Classe C
            Descrição da Média Geral 2021
                                2238106.00
                                                                             358669.00
     count
                                    535.54
                                                                                588.45
    mean
                                     88.96
                                                                                 85.47
     std
    min
                                      0.00
                                                                                   0.00
     25%
                                    471.40
                                                                                527.66
    50%
                                    527.32
                                                                                588.78
```

```
75% 594.48 649.60 max 862.68 862.68
```

```
[6]: # DESCRIÇÃO DA MÉDIA GERAL CLASSE B
     media_geral_classe_b_2019 = df_2019.query("Q006 == 'B'")["NU_MEDIA_GERAL"].
      →describe(
         include=['object', 'float64', 'int64']).apply(lambda s: np.round(s, 2))
     media_geral_classe_b_2020 = df_2020.query("Q006 == 'B'")["NU_MEDIA_GERAL"].
         include=['object', 'float64', 'int64']).apply(lambda s: np.round(s, 2))
     media_geral_classe_b_2021 = df_2021.query("Q006 == 'B'")["NU_MEDIA_GERAL"].
      ⊶describe(
         include=['object', 'float64', 'int64']).apply(lambda s: np.round(s, 2))
     df = pd.concat([media_geral_2019, media_geral_classe_b_2019,
                     media geral 2020, media geral classe b 2020,
                     media_geral_2021, media_geral_classe_b_2021],
                      keys=['Descrição da Média Geral 2019',
                            'Descrição da Média Geral 2019 - Classe B',
                            'Descrição da Média Geral 2020',
                            'Descrição da Média Geral 2020 - Classe B',
                            'Descrição da Média Geral 2021',
                            'Descrição da Média Geral 2021 - Classe B'],
                      axis=1)
     df
```

```
[6]:
            Descrição da Média Geral 2019 \
                                3701909.00
     count
     mean
                                     522.62
                                      83.65
     std
     min
                                       0.00
     25%
                                     464.04
     50%
                                     515.02
     75%
                                     576.74
                                     850.82
     max
            Descrição da Média Geral 2019 - Classe B \
                                             129646.00
     count
                                                620.45
     mean
     std
                                                 77.41
                                                  0.00
     min
     25%
                                                571.26
     50%
                                                626.48
     75%
                                                676.10
```

max

850.82

```
2561304.00
     count
     mean
                                    526.60
     std
                                     91.52
                                      0.00
    min
     25%
                                    459.38
     50%
                                    516.88
    75%
                                    587.16
    max
                                    858.58
            Descrição da Média Geral 2020 - Classe B \
                                             84249.00
     count
    mean
                                               630.08
     std
                                                84.47
    min
                                               125.08
     25%
                                               574.94
     50%
                                               636.28
     75%
                                               691.28
    max
                                               852.86
            Descrição da Média Geral 2021 Descrição da Média Geral 2021 - Classe B
                               2238106.00
                                                                             95692.00
     count
    mean
                                    535.54
                                                                               619.80
     std
                                     88.96
                                                                                84.68
    min
                                      0.00
                                                                                 0.00
    25%
                                    471.40
                                                                               562.92
     50%
                                    527.32
                                                                               624.51
     75%
                                    594.48
                                                                               681.34
    max
                                    862.68
                                                                               851.04
[7]: # DESCRIÇÃO DA MÉDIA GERAL CLASSE A
     media_geral_classe_a_2019 = df_2019.query("Q006 == 'A'")["NU_MEDIA_GERAL"].
      →describe(
         include=['object', 'float64', 'int64']).apply(lambda s: np.round(s, 2))
     media_geral_classe_a_2020 = df_2020.query("Q006 == 'A'")["NU_MEDIA_GERAL"].
      ⊶describe(
         include=['object', 'float64', 'int64']).apply(lambda s: np.round(s, 2))
     media_geral_classe_a_2021 = df_2021.query("Q006 == 'A'")["NU_MEDIA_GERAL"].
      ⊶describe(
         include=['object', 'float64', 'int64']).apply(lambda s: np.round(s, 2))
     df = pd.concat([media_geral_2019, media_geral_classe_a_2019,
                     media_geral_2020, media_geral_classe_a_2020,
                     media_geral_2021, media_geral_classe_a_2021],
                      keys=['Descrição da Média Geral 2019',
                             'Descrição da Média Geral 2019 - Classe A',
                             'Descrição da Média Geral 2020',
```


Descrição da Média Geral 2020 \


```
'Descrição da Média Geral 2021',
                             'Descrição da Média Geral 2021 - Classe A'],
                       axis=1)
     df
[7]:
            Descrição da Média Geral 2019 \
                                3701909.00
     count
     mean
                                    522.62
     std
                                     83.65
    min
                                      0.00
     25%
                                    464.04
    50%
                                    515.02
    75%
                                    576.74
                                    850.82
    max
            Descrição da Média Geral 2019 - Classe A \
                                              46659.00
     count
                                                637.32
    mean
     std
                                                 75.49
                                                  0.00
    min
     25%
                                                592.66
     50%
                                                644.88
     75%
                                                690.94
    max
                                                837.48
            Descrição da Média Geral 2020 \
                                2561304.00
     count
                                    526.60
    mean
     std
                                     91.52
    min
                                      0.00
    25%
                                    459.38
     50%
                                    516.88
     75%
                                    587.16
    max
                                    858.58
            Descrição da Média Geral 2020 - Classe A \
                                              31582.00
     count
    mean
                                                644.74
     std
                                                 83.97
    min
                                                  0.00
     25%
                                                591.84
    50%
                                                652.10
    75%
                                                705.76
                                                852.76
    max
```


'Descrição da Média Geral 2020 - Classe A',

	Descrição da Média Geral 2021	Descrição da Média Geral 2021 - Classe A
count	2238106.00	39914.00
mean	535.54	632.34
std	88.96	84.49
min	0.00	73.16
25%	471.40	576.34
50%	527.32	638.49
75%	594.48	693.86
max	862.68	859.96

```
[8]: utils.plot_hist_classes_all(df_2019, OUTPUT)
utils.plot_hist_classes_all(df_2020, OUTPUT)
utils.plot_hist_classes_all(df_2021, OUTPUT)
```










```
[9]: utils.plot_hist_classes(df_2019, OUTPUT)
utils.plot_hist_classes(df_2020, OUTPUT)
utils.plot_hist_classes(df_2021, OUTPUT)
```

Número de pessoas x Nota da Redação - 2019 - 3701909 candidatos





Número de pessoas x Nota da Redação - 2020 - 2561304 candidatos






```
[10]: utils.plot_hist_boxplot_classes(df_2019, OUTPUT)
   utils.plot_hist_boxplot_classes(df_2020, OUTPUT)
   utils.plot_hist_boxplot_classes(df_2021, OUTPUT)
```







[11]: utils.plot_boxplot_descricao_amostras([df_2019, df_2020, df_2021], OUTPUT)

